

MAE-AST: Masked Autoencoding Audio Spectrogram Transformer

Elaborato di Deep Learning

Alessio Poggesi

Università degli Studi di Firenze



UNIVERSITÀ
DEGLI STUDI
FIRENZE

Da un secolo, oltre.

Il lavoro di riferimento

MAE-AST: Masked Autoencoding Audio Spectrogram Transformer

MAE-AST: Masked Autoencoding Audio Spectrogram Transformer

Alan Baade Puyuan Peng David Harwath

Department of Computer Science The University of Texas at Austin

Interspeech 2022

Tema del lavoro

Pretraining **self-supervised** degli Audio Spectrogram Transformer per task di speech e audio classification, con particolare attenzione all'efficienza computazionale del masked pretraining.

Table of Contents

1 Introduzione

- **Introduzione**
- Dataset
- Preprocessing
- Architettura
- Valutazione e risultati del paper
- Esperimenti
- Risultati principali
- Confronto con il paper
- Conclusioni

Da SSAST a MAE-AST

Il problema computazionale del masked pretraining audio

SSAST: self-supervised pretraining per l'audio

- lo spettrogramma viene suddiviso in patch e trattato come una sequenza di token;
- una parte consistente dell'input viene mascherata;
- il modello apprende a predire le patch nascoste senza supervisione sulle label.

Il problema

Con un mask ratio del **75%**:

512 patch

128
visibili

+

384
mascherate

Nell'approccio full-sequence, l'encoder Transformer continua a elaborare l'intera sequenza.

512 token → encoder profondo

Con masking elevato, una parte consistente del compute dell'encoder viene quindi spesa sui mask token.

L'idea MAE

Spostare i mask token fuori dall'encoder profondo




Figura tratta da: K. He, X. Chen, S. Xie, Y. Li, P. Dollár, R. Girshick, *Masked Autoencoders Are Scalable Vision Learners*, CVPR 2022, Fig. 1.

Pretraining

- le patch mascherate vengono rimosse prima dell'encoder;
- l'encoder elabora solo i **token visibili**;
- i mask token vengono reinseriti successivamente;
- un decoder leggero lavora sulla sequenza completa.

Con il 75% di masking: $512 \rightarrow 128$ token nell'encoder.

Fine-tuning: il decoder viene scartato; l'encoder preaddestrato viene applicato all'input completo per il task downstream.

Il nostro progetto

Reimplementazione e studio sperimentale di MAE-AST

Reimplementazione in PyTorch

- implementazione modulare dell'architettura MAE-AST;
- pretraining self-supervised su un subset di **AudioSet** di circa 500k clip;
- valutazione downstream su **ESC-50** con protocollo ufficiale 5-fold;
- benchmark controllato del vantaggio computazionale dell'encoder MAE.

Domande sperimentali

- Q1** Come cambiano le rappresentazioni apprese variando **profondità**, **strategia di masking** e **mask ratio**?
- Q2** Qual è il contributo delle componenti **generativa** e **discriminativa** della loss di pretraining?
- Q3** Quanto compute e memoria si risparmiano elaborando nell'encoder soltanto i token visibili?

Table of Contents

2 Dataset

- ▶ Introduzione
- ▶ **Dataset**
- ▶ Preprocessing
- ▶ Architettura
- ▶ Valutazione e risultati del paper
- ▶ Esperimenti
- ▶ Risultati principali
- ▶ Confronto con il paper
- ▶ Conclusioni

Dataset di pretraining

Analisi del dataset



Paper MAE-AST Il pretraining originale utilizza:

- **AudioSet-2M**: circa 2 milioni di clip da 10 s;
- **LibriSpeech**: 960 ore di parlato.



`confit/audioset-16khz-wds`
configurazione 500k

- mirror pubblico di **AudioSet**;
- audio già convertito a **16 kHz**;
- metadata originali associati alle clip.



Analisi esplorativa del dataset

Verifica del corpus prima del pretraining

Integrità del corpus

- **490 548 / 490 548** clip leggibili;
- **0** file corrotti;
- **0** `source_id` duplicati;
- **100%** audio mono;
- **100%** sample rate a 16 kHz;
- **527** label presenti nei metadata.

Durata delle clip

Statistica	Valore
Media	9.915 s
Mediana	10.000 s
Minimo	0.135 s
Massimo	10.012 s
Clip < 5 s	0.33%

Padding

Statistica	Valore
Padding medio	3.37%
Patch interessate	3.97%
Clip troncate	0
Target temporale	1024 frame


Table of Contents

3 Preprocessing

- ▶ Introduzione
- ▶ Dataset
- ▶ **Preprocessing**
- ▶ Architettura
- ▶ Valutazione e risultati del paper
- ▶ Esperimenti
- ▶ Risultati principali
- ▶ Confronto con il paper
- ▶ Conclusioni

Dalla waveform ai frame

Segmentazione temporale del segnale audio



Dal segnale ai frame

Passaggio	Valore
Sample rate	16 kHz
Campioni in 1 s	16 000
Frame length	25 ms = 400 campioni
Frame shift	10 ms = 160 campioni
Overlap	15 ms = 240 campioni
Frame in 1 s	≈ 98

$$\text{Frame} = [0.12, -0.08, 0.31, \dots, -0.04] \in \mathbb{R}^{400}$$

Dal frame allo spettrogramma log-Mel

Costruzione della rappresentazione tempo-frequenza

Per ogni frame

1. **400 campioni** della waveform;
2. analisi dello **spettro in frequenza**;
3. aggregazione tramite **128 filtri Mel**;
4. trasformazione in scala **logaritmica**.


Output del frame

$$F_t = [m_1, \dots, m_{128}]$$

Un vettore di **128 valori log-Mel**.




Ripetendo sui T frame della clip si
ottiene lo spettrogramma:



Dallo spettrogramma alle patch

Input a lunghezza fissa e patchification 16×16




Dalla patch al token

Proiezione nello spazio di embedding del Transformer

Rappresentazione della patch

- ogni patch copre una regione locale **tempo-frequenza**;
- dimensione della patch: 16×16 ;
- ogni patch contiene **256 valori log-Mel**;

Passaggio	Dimensione
Patch 16×16	256
Content embedding	768
Positional embedding	768
Token finale	768



Strategie di masking

Quali patch vengono nascoste durante il pretraining


Random masking

- patch selezionate in modo **casuale**;
- informazione visibile distribuita sull'intero spettrogramma.


Chunk masking

- patch mascherate in **regioni contigue**;
- chunk di dimensione 3^2 , 4^2 o 5^2 patch.


random masking — 50% masked




random masking — 75% masked



chunk masking — 50% masked



chunk masking — 75% masked



Mask	Masked	Visible
50%	256	256
75%	384	128



Su **512 token iniziali**, il masking determina quanti token vengono poi elaborati.


Table of Contents

4 Architettura

- ▶ Introduzione
- ▶ Dataset
- ▶ Preprocessing
- ▶ **Architettura**
- ▶ Valutazione e risultati del paper
- ▶ Esperimenti
- ▶ Risultati principali
- ▶ Confronto con il paper
- ▶ Conclusioni

Architettura MAE-AST

Dal token audio al pretraining auto-supervisionato



Pretraining auto-supervisionato

Encoder sui token visibili, decoder sulla sequenza completa

Encoder

- input iniziale: **512 token**;
- vengono rimosse le patch mascherate;
- entrano soltanto i token **visibili**;
- encoder Transformer da **6 o 12 layer**.

Mask ratio	Token encoder
50%	256
75%	128

Decoder

- reinserimento dei **mask token**;
- ripristino delle **512 posizioni**;
- aggiunta dell'informazione posizionale;
- decoder leggero da **2 layer**.

$$128/256 \rightarrow \boxed{512}$$

Il decoder ricostruisce le rappresentazioni delle patch nascoste.

Il costo principale viene ridotto perché l'**encoder profondo non elabora i token mascherati**.

Obiettivo di pretraining

Ricostruzione e discriminazione delle patch mascherate

Reconstruction loss

- applicata alle patch mascherate;
- confronta ricostruzione e target log-Mel;
- implementata tramite **MSE**.

$$\mathcal{L}_{rec}$$

Discriminative loss


- distingue il target corretto tra patch candidate;
- sfrutta relazioni **intra-clip**;
- non utilizza le label AudioSet.

$$\mathcal{L}_{cls}$$

$$\mathcal{L} = 10 \mathcal{L}_{rec} + \mathcal{L}_{cls}$$

Dal pretraining al fine-tuning

Riutilizzo dell'encoder per la classificazione audio



Fine-tuning

- nessun masking;
- decoder **rimosso**;
- tutti i token attraversano l'encoder;
- mean pooling delle rappresentazioni;
- classificazione supervisionata.



L'encoder pre-addestrato viene quindi valutato su **sei downstream task** di audio e speech classification.

Table of Contents

5 Valutazione e risultati del paper

- ▶ Introduzione
- ▶ Dataset
- ▶ Preprocessing
- ▶ Architettura
- ▶ **Valutazione e risultati del paper**
- ▶ Esperimenti
- ▶ Risultati principali
- ▶ Confronto con il paper
- ▶ Conclusioni

Valutazione downstream

Sei task per valutare le rappresentazioni apprese

Audio event classification

- **AudioSet (AS)**
classificazione generale di eventi audio;
- **ESC-50 (ESC)**
classificazione di suoni ambientali.

Speech classification

- **Speech Commands 1/2**
keyword spotting (KS1, KS2);
- **VoxCeleb**
speaker identification (SID);
- **IEMOCAP**
emotion recognition (ER).

La stessa rappresentazione pre-addestrata viene quindi testata su task con caratteristiche molto diverse.

Risultati downstream del paper

MAE-AST rispetto a SSAST

Model	Enc. Layers	Masking	AS	ESC	KS2	KS1	SID	ER
SSAST Base Patch	12	Chunked	28.6	88.8	98.0	96.0	64.3	59.6
SSAST Base Frame	12	Random	-	85.9	98.1	96.7	80.8	60.5
MAE-AST Patch	6	Chunked	28.3	88.6	97.4	95.0	37.6	58.7
MAE-AST Frame	6	Random	25.9	88.0	97.8	96.6	58.6	60.2
MAE-AST Patch	12	Chunked	30.6	90.0	97.9	95.8	-	59.8
MAE-AST Frame	12	Random	23.0	88.9	98.0	97.3	63.3	62.1

- MAE-AST risulta **competitivo con SSAST** sui diversi task downstream;
- il setting **patch-based** è particolarmente efficace nei task di **audio event classification**;
- il setting **frame-based** mantiene buone prestazioni nei task legati allo **speech**;
- il vantaggio di MAE-AST non riguarda solo l'efficienza: le rappresentazioni apprese restano **trasferibili ai task downstream**.

Ablation study del paper

Quali componenti influenzano il pretraining?

Input	%p	Masking	AS	KS2	ER
Patch	50	Random	27.6	97.4	57.3
Patch	50	Chunk	27.8	97.4	58.2
Patch	75	Random	26.7	97.4	58.6
Patch	75	Chunk	28.3	97.4	58.7
Frame	50	Random	23.6	97.8	59.1
Frame	50	Chunk	24.9	97.9	62.1
Frame	75	Random	25.9	97.8	60.2
Frame	75	Chunk	23.4	97.9	61.8

Table 3 — Masking strategies

Mask	Lay.	Sec/Ep	Mem. (MiB)	Speedup
75%	6	7016	6291	1.80×
75%	12	8299	8227	2.96×
50%	12	12222	11639	2.01×
w/ [M]	6	12636	9871	-
w/ [M]	12	24577	17719	-
SSAST [8]	12	150755	41547	-

Table 4 — Pretraining efficiency

Model	AS	ESC	KS2	KS1	SID	ER
SSAST Gen	12.2	74.2	96.6	93.3	40.1	54.3
SSAST Disc	29.6	85.6	98.0	94.2	61.4	57.5
Ours Gen	26.1	86.3	97.3	95.1	40.6	58.6
Ours Disc	28.5	89.0	97.3	94.6	38.8	58.3

Table 5 — Pretext task

Le ablation analizzano l'impatto di **masking**, **efficienza computazionale** e **obiettivi di pretraining**.

Table of Contents

6 Esperimenti

- ▶ Introduzione
- ▶ Dataset
- ▶ Preprocessing
- ▶ Architettura
- ▶ Valutazione e risultati del paper
- ▶ **Esperimenti**
- ▶ Risultati principali
- ▶ Confronto con il paper
- ▶ Conclusioni

Piano sperimentale

Otto configurazioni per isolare l'effetto delle principali scelte di pretraining

Encoder: 6L / 12L

Masking: Random / Chunk

Mask ratio: 50% / 75%

$$2 \times 2 \times 2 = 8 \text{ configurazioni}$$

Run	Encoder	Masking	Mask ratio
M1	6L	Random	50%
M2	6L	Chunk	50%
M3	6L	Random	75%
M4	6L	Chunk	75%
M5	12L	Random	50%
M6	12L	Chunk	50%
M7	12L	Random	75%
M8	12L	Chunk	75%

Setup computazionale: NVIDIA RTX 5090 (~32 GB)

Protocollo sperimentale

Condizioni comuni alle otto configurazioni M1-M8

Pretraining

- dataset: **AudioSet-500k**;
- input log-Mel: 1024×128 ;
- patch: $16 \times 16 \rightarrow 512$ token;
- embedding dimension: **768**;
- decoder fisso: **2 layer**;
- loss congiunta:

$$\mathcal{L} = 10\mathcal{L}_{rec} + \mathcal{L}_{cls};$$

- optimizer: **AdamW**, $lr = 10^{-4}$;
- training: **16 epoche**, batch size 32.

Valutazione downstream

- dataset: **ESC-50**;
- protocollo ufficiale: **5-fold cross-validation**;
- per ogni fold:
 - 1600 clip di training;
 - 400 clip held-out;
- nessun masking;
- decoder rimosso;
- risultato finale: **mean $\pm$ std** sui 5 fold.


Table of Contents

7 Risultati principali

- ▶ Introduzione
- ▶ Dataset
- ▶ Preprocessing
- ▶ Architettura
- ▶ Valutazione e risultati del paper
- ▶ Esperimenti
- ▶ **Risultati principali**
- ▶ Confronto con il paper
- ▶ Conclusioni

Risultati M1-M8

Accuracy media su ESC-50 nei cinque fold





Run	Layer	Mask	Ratio	ESC-50 (%)
M1	6L	Random	50%	82.50 ± 3.05
M2	6L	Chunk	50%	84.45 ± 2.77
M3	6L	Random	75%	83.55 ± 2.25
M4	6L	Chunk	75%	84.35 ± 1.46
M5	12L	Random	50%	84.00 ± 2.88
M6	12L	Chunk	50%	85.90 ± 1.49
M7	12L	Random	75%	85.15 ± 3.00
M8	12L	Chunk	75%	84.50 ± 1.94

M6: 12L + Chunk + 50%

- la configurazione migliore è **M6: 12L, Chunk masking, 50%**, con **85.90% ± 1.49**;
- le otto configurazioni si collocano tra **82.50% e 85.90%**, mostrando l'impatto delle diverse scelte di pretraining.

Effetto delle scelte di pretraining




Profondità, strategia di masking e mask ratio



In media, gli effetti maggiori derivano da **encoder più profondo** e **Chunk masking**; il solo aumento del mask ratio produce un effetto medio più contenuto.

Convergenza del pretraining e qualità downstream

La loss assoluta non determina direttamente l'accuracy su ESC-50



Le curve mostrano una convergenza regolare del pretraining, ma la **loss assoluta** dipende anche dalla difficoltà del pretext task e non costituisce da sola un ranking della qualità downstream.


Ablation della funzione obiettivo

Contributo delle componenti generativa e discriminativa

Setup controllato

- encoder: **6 layer**;
- masking: **Chunk 75%**;
- decoder: **2 layer**;
- stesso protocollo di pretraining e fine-tuning.

Run	Objective
L1	Reconstruction only
L2	Discriminative only
M4	Joint



- **reconstruction-only:** 80.60% $\pm$ 1.80;
- **discriminative-only:** 84.60% $\pm$ 0.87;
- **joint:** 84.35% $\pm$ 1.46.

Benchmark di efficienza

MAE-AST rispetto a una baseline full-sequence controllata

MAE-AST

- sequenza iniziale: **512 token**;
- masking prima dell'encoder:
 - 50% → **256 token**;
 - 75% → **128 token**;
- decoder sulla sequenza completa.

FullSequenceProxy

- stessa dimensione di input;
- encoder su **tutti i 512 token**;
- mantiene decoder e heads;
- baseline utilizzata per isolare il vantaggio del masking MAE.

Protocollo di misura



Parametro	Valore
Batch size	32
Warm-up	20 step
Step misurati	100
Ripetizioni	5
Precisione	AMP

Lo step include

forward → loss → backward → optimizer

Risultati del benchmark

Speed-up e riduzione della memoria GPU



- il vantaggio cresce aumentando il **mask ratio** e la profondità dell'encoder;
- il massimo beneficio si osserva con **12L e 75% di masking**: **$2.13\times$ speed-up** e **49.10% di memoria in meno**.

Table of Contents

8 Confronto con il paper

- ▶ Introduzione
- ▶ Dataset
- ▶ Preprocessing
- ▶ Architettura
- ▶ Valutazione e risultati del paper
- ▶ Esperimenti
- ▶ Risultati principali
- ▶ **Confronto con il paper**
- ▶ Conclusioni

Confronto con il lavoro originale

Quali tendenze ritroviamo nella nostra reimplementazione?

Profondità dell'encoder

	6 layer	12 layer
Paper — Chunk	88.6%	90.0%
Noi — Chunk	84.45% (M2)	85.90% (M6)

⇒ In entrambi i casi un **encoder più profondo** migliora le prestazioni downstream.

Strategia di masking

Paper	Nostro progetto
Chunk favorevole nel setting patch-based	6L: M1 82.50 → M2 84.45 12L: M5 84.00 → M6 85.90

⇒ Anche da noi il **Chunk** risulta generalmente più efficace del Random.

Mask ratio

Paper	Nostro progetto
75% + Chunk favorevole nel setting patch-based	6L: M2 84.45 vs M4 84.35 12L: M6 85.90 vs M8 84.50

⇒ Nel nostro setting il **75%** non migliora il risultato: il best model usa il **50%**.

Confronto della funzione obiettivo

Componente generativa e discriminativa

Paper MAE-AST

Objective	ESC-50
Generative	86.3%
Discriminative	89.0%

Sul task audio ESC-50 la componente **discriminativa** ottiene prestazioni superiori alla sola ricostruzione.

Nostra reimplementazione

Objective	ESC-50
Reconstruction-only	80.60 $\pm$ 1.80
Discriminative-only	84.60 $\pm$ 0.87

Anche nel nostro setting la componente **discriminativa** risulta determinante per la qualità downstream.

Il confronto evidenzia la stessa tendenza qualitativa: nei task audio la sola ricostruzione non è sufficiente a ottenere le migliori rappresentazioni.

Confronto dell'efficienza

Lo stesso vantaggio architetturale emerge nelle due implementazioni

Speed-up

Setup	Paper	Nostro progetto
6L - 75%	1.80×	1.74×
12L - 50%	2.01×	1.67×
12L - 75%	2.96×	2.13×

Memoria

Setup	Paper	Nostro progetto
12L - 75%	53.6% in meno	49.10% in meno

- in entrambi i casi il massimo beneficio emerge con **12 layer e 75% di masking**;
- aumentando la quota di token esclusi dall'encoder profondo, cresce il vantaggio in **tempo e**

Table of Contents

9 Conclusioni

- ▶ Introduzione
- ▶ Dataset
- ▶ Preprocessing
- ▶ Architettura
- ▶ Valutazione e risultati del paper
- ▶ Esperimenti
- ▶ Risultati principali
- ▶ Confronto con il paper
- ▶ **Conclusioni**

Conclusioni e limiti

Sintesi finale della reimplementazione

Conclusioni

- miglior modello: **M6**, 12L + Chunk + 50%, con **85.90% $\pm$ 1.49**;
- encoder più profondo e **Chunk masking** risultano generalmente favorevoli;
- la componente **discriminativa** è determinante sul downstream audio;
- il masking MAE riduce il costo: fino a **2.13 $\times$** e **49.10%** di memoria in meno.

Limiti

- pretraining su **AudioSet-500k**, a scala inferiore rispetto al paper;
- valutazione downstream concentrata su **ESC-50**;
- studio focalizzato sul setting **patch-based**;
- baseline di efficienza controllata, non replica bit-per-bit di SSAST.

La reimplementazione conferma le **principali tendenze qualitative di MAE-AST**, pur con differenze di scala e protocollo sperimentale.

MAE-AST: Masked Autoencoding Audio Spectrogram Transformer

Thank you for listening!
Any questions?

Riferimenti

9 Conclusioni

Progetto

- github.com/alessiopgg/deep_learning

Paper

- Baade, Peng, Harwath, *MAE-AST: Masked Autoencoding Audio Spectrogram Transformer*
[arXiv:2203.16691](https://arxiv.org/abs/2203.16691)
- Gong et al., *SSAST: Self-Supervised Audio Spectrogram Transformer*
[arXiv:2110.09784](https://arxiv.org/abs/2110.09784)
- He et al., *Masked Autoencoders Are Scalable Vision Learners*
[arXiv:2111.06377](https://arxiv.org/abs/2111.06377)
- Gong, Chung, Glass, *AST: Audio Spectrogram Transformer*
[arXiv:2104.01778](https://arxiv.org/abs/2104.01778)

Dataset e codice

- AudioSet: research.google.com/audioset
- ESC-50: github.com/karolpiczak/ESC-50
- MAE-AST code: github.com/AlanBaade/MAE-AST-Public
- AudioSet-16k WDS: [confit/audioset-16khz-wds](https://confit.github.io/audioset-16khz-wds)